

Использование численного анализа для получения решений физических моделей стало неотъемлемой частью науки. Он применяется для прогнозов погоды и климата, в квантовой физике, а также для управления плазменным синтезом.

В последнее время технологии машинного обучения и, в частности, глубокие нейронные сети привели к впечатляющим достижениям в самых разных областях: от классификации изображений до обработки естественного языка. Эта область очень динамична и быстро развивается, обещая огромные возможности. Эта история успеха глубокого обучения породила опасение, что эта технология имеет потенциал, чтобы заменить традиционный подход к науке. Например, недавние работы показывают, что суррогатные модели на основе нейронных сетей достигают точности, необходимой для реальных промышленных применений, таких как аэродинамические потоки, в то же время превосходя традиционные методы вычислений в разы с точки зрения времени выполнения. Но можно ли вместо того, чтобы полагаться на модели, тщательно разработанные на основе первых принципов моделирования, обрабатывать объёмы данных достаточного размера для получения правильных ответов? Это беспокойство беспочвенно, так как, скорее, для следующего поколения систем моделирования крайне важно соединить оба мира: объединить классические численные методы с методами глубокого обучения.

Одной из основных причин важности этой комбинации является то, что подходы глубокого обучения являются мощными, но в то же время сильно выигрывают от знаний предметной области физических моделей. Методы глубокого обучения и нейронных сетей являются новыми, иногда трудными для применения, и зачастую непросто правильно интегрировать наше понимание физических процессов в алгоритмы обучения. Но данные методы имеют огромный потенциал для улучшения того, что можно сделать с помощью численных методов: например, в задаче где решатель многократно нацеливается на случаи из чётко определённой проблемной области, имеет смысл один раз вложить значительные ресурсы для обучения нейронной сети, которая поддерживает повторные решения. Основываясь на предметной специализации этой сети, такой гибрид может значительно превзойти традиционные универсальные решатели.

Другой способ взглянуть на это заключается в том, что все математические модели нашей природы являются идеализированными приближениями и содержат ошибки. Было приложено много усилий для получения очень хороших уравнений моделей, но чтобы сделать следующий большой шаг вперёд, методы глубокого обучения предлагают очень мощный инструмент для закрытия оставшегося разрыва по отношению к реальному миру.